

Chair of Renewable and Sustainable Energy Systems

Technische Universität München



**Building Energy Management System
Based on Multi-Agent Deep
Reinforcement Learning**

Master's Thesis submitted for the degree of Master of Science
(M.Sc.) in Energy and Process Engineering

Author:	Yuxin Wen
Matriculation No.:	03782672
Program:	M.Sc. Energy and Process Engineering
Supervisor:	Jun Zhang
Submission Date:	01.08.2026

Contents

1	State of the Art	1
1.1	分布式电网中的 Energy Management	1
1.2	现有的控制方法	2
1.3	面临的挑战与 Research Gap	5
	Bibliography	7

1 State of the Art

本章围绕本文研究主题，对分布式配电网中的能源管理问题、现有控制方法以及仍然存在的研究空缺进行综述。本文关注的对象不是单个孤立家庭的用电优化，而是低压配电网中多个 prosumer 的协同能源管理问题。每个 prosumer 同时包含 household load、PV generation、stationary battery energy storage system 和 residential EV charging demand，控制器需要在动态电价、可再生能源波动、EV 离家 SoC 需求以及配电网运行约束之间进行权衡。因此，本章首先介绍 HEMS 和分布式电网能源管理的基本发展脉络，然后讨论 rule-based、optimization-based、MPC、machine learning、DRL 和 MADRL 等已有方法，最后总结这些方法在本文问题设置下仍然存在的不足，并引出本文的研究内容。

1.1 分布式电网中的 Energy Management

随着 smart grid、advanced metering infrastructure、bidirectional communication 和 residential distributed energy resources 的发展，家庭用户逐渐从传统的被动负荷转变为能够主动参与电网运行的 prosumer。Zhou 等人对 smart HEMS 的概念、架构、功能模块和调度策略进行了综述，指出 HEMS 可以通过 renewable energy、home energy storage、smart appliances 和 demand response 的协调，提高住宅侧能源利用效率并降低用电成本 [34]。Ali 等人进一步从 closed-loop control 的角度总结了 HEMS 在 smart grid 中的结构，强调 HEMS 不仅涉及家庭内部设备调度，还需要与 demand side management、demand response、通信网络和监测设备共同工作 [1]。Beaudin 和 Zareipour 则从建模复杂度出发指出，HEMS 研究中的目标函数、设备模型、用户舒适度、预测不确定性和计算复杂度差异较大，这使得不同方法之间的比较并不直接 [3]。

在分布式能源管理中，PV、BESS 和 EV 是最重要的灵活资源之一。PV 可以降低用户从电网购电的需求，但其出力具有间歇性，并可能在低负荷、高发电时段导致反向潮流和电压问题。Clastres 等人研究了 household PV production 参与 ancillary services 的可能性，表明住宅 PV 系统如果与负荷和其他资源协同管理，可以在市场机制下提高经济价值，但同时也受到 PV 间歇性和负荷不确定性的影响 [6]。Dongol 等人在 rural low-voltage grid 中研究了带 PV 的 household battery MPC peak shaving，说明住宅电池可用于平滑 PV feed-in 和负荷峰值，但其效果依赖于预测信息和控制目标的设计 [8]。Manjunatha 等人提出了基于 model predictive control 的大型 BESS 接入 distribution grid 的控制器，展示了电池在 peak shaving、cost-optimal control 和 time-varying price 场景下的应用潜力 [15]。Id Omar 等人进一步从 behind-the-meter BESS 的角度讨论了

本地服务和电网服务的 stacked control, 包括 PV self-consumption、peak-load reduction 和 balancing service, 说明 BESS 已经不仅是家庭内部成本优化工具, 也可以作为 grid service 的灵活性资源 [9]。

EV 的大规模接入进一步增加了 residential energy management 的复杂度。一方面, EV 是可调度负荷, 其充电可以根据电价和用户出行需求进行移位; 另一方面, EV 具有明确的 connection window、charging power limit 和 departure SoC requirement。Wang 等人综述了 fast charging station 对电网的影响, 指出高功率 EV charging 会带来 voltage fluctuation、harmonics、power quality 和 grid stability 等问题 [26]。Seal 等人研究了将 EV 作为 mobile energy storage unit 纳入 centralized MPC-based HEMS 的问题, 并通过 Monte Carlo 分析讨论了 EV 到达、离开和 trip discharge 的不确定性对控制性能的影响 [22]。Park 和 Moon 则针对 smart grid 中多个 EV 的充电调度提出 MADRL 方法, 强调 decentralized execution 更适合需要快速决策和多车辆状态差异的实际充电环境 [18]。这些研究说明, EV 建模不能只把 EV 看作普通负荷, 而需要显式考虑到达时间、离开时间、SoC 演化和用户需求。

从系统层面看, 分布式电网中的 energy management 需要同时面对用户侧经济性和电网侧运行要求。Makhadmeh 等人对 smart home power scheduling problem 进行了综述, 指出动态电价下的 appliance scheduling 主要目标通常包括降低电费、降低 peak-to-average ratio 和提高用户舒适度 [14]。Satpathy 和 Ramachandaramurthy 从 DERMS 的角度综述了 AI 和 machine learning 在 forecasting、optimization、real-time control、demand-side management 和 energy trading 中的应用, 指出 DER 的 decentralized、variable 和 bidirectional 特性使传统电力系统运行更加复杂 [21]。因此, 在本文所研究的低压配电网中, energy management 不仅要安排单个家庭内部设备, 还要处理多个 prosumer 的同时动作对 feeder net load、voltage profile 和 transformer loading 的共同影响。

1.2 现有的控制方法

早期 HEMS 控制方法通常采用 rule-based 或 heuristic 策略。这类方法实现简单、计算量低, 适合实际部署, 但缺少对未来电价、PV 和负荷变化的系统性预见。Shakeri 等人提出了一种 HEMS architecture 和 control algorithm, 使家庭设备根据电价、battery status 和 thermal appliance 状态进行运行切换, 仿真表明可以降低每日用电成本, 但其控制逻辑仍然依赖人工设定规则 [23]。Costanzo 等人将 smart home peak-load shaving 表述为 online scheduling 问题, 说明在线调度可以降低峰值负荷, 但其方法主要关注 appliance scheduling, 并未覆盖更复杂的多储能、多 prosumer 协同问题 [7]。Wu 等人提出 residential microgrid 中 hybrid hydrogen-electricity storage 的 hierarchical online EMS, 通过 fuzzy logic controller 实现不同时间尺度的能量管理; 该方法能够避免对预测模型的依赖, 但作者也指出缺少 foresight 可能导致无法稳定地在低价时段购电 [28]。Rahim 等人比较了 GA、BPSO 和 ACO 等 heuristic algorithms 在 home energy management

controller 中的效果, 说明启发式方法可以降低电费和 peak-to-average ratio, 但其性能依赖算法设计和问题建模 [20]。Sisodiya 等人使用 PSO 对包含 EV 和 UPS 的家庭设备进行 demand response 调度, 展示了 metaheuristic 方法在家庭储能和负荷管理中的应用 [25]。

Optimization-based 方法能够更明确地表达设备约束、用户舒适度和经济目标。Zhang 等人提出结合 machine learning、optimization 和 data structure design 的 demand response and HEM system, 将家庭负荷分为 fixed、regulatable 和 deferrable 三类, 并为 HVAC 建立 learning-based energy consumption model, 再结合优化生成 DR 策略 [30]。Jin 等人的 Foresee HEMS 采用 multiobjective MPC 框架, 同时考虑 energy cost、thermal comfort、user convenience 和 carbon emission, 并利用 machine-learning algorithms 学习 appliance models 和 usage patterns, 从而在保证用户需求的同时提供 demand response 服务 [10]。Chen 等人提出 MPC-based appliance scheduling, 在 time-varying retail pricing 下对 thermal 和 non-thermal appliances 进行 finite-horizon optimization, 并通过滚动更新利用新的预测信息 [5]。Beaudin 等人提出 moving window algorithm, 用周期性更新预测来增强 residential energy management 对 forecast errors 和扰动的鲁棒性 [4]。Zheng 等人从 residential sector demand response 的角度研究建筑储能的 load shifting 和 peak reduction, 说明 storage 可以在不改变实际用电行为的情况下提供 DR 能力 [33]。

MPC 的优势在于可以在每个 rolling horizon 内显式处理 SoC dynamics、power limits、comfort bounds 和 forecast information, 因此非常适合 BESS、EV 和 PV 的调度问题。然而, MPC 和 mixed-integer optimization 也存在计算复杂度、模型依赖和求解器依赖问题。Mueller 等人比较了 rule-based、MPC、imitation learning 和 reinforcement learning 在 German low-voltage benchmark grid 中控制多个 household BESS 的效果, 结果表明 model-based 方法在 objective value 和 constraint violations 方面通常最好, 但计算时间更高; model-free 方法计算负担较低, 但可能带来更高目标函数值和更多 grid constraint violations [17]。这一结论与本文的 baseline 设计密切相关: MPC、ADMM-MPC 和 MISOCP 可以作为强优化基线, 但在多 prosumer、带 EV 和配电网约束的场景下, 其计算成本和模型要求也需要被评估。

随着 smart meter 和 residential data 的增加, machine learning 和 reinforcement learning 被逐渐用于 HEMS。Liu 等人使用 DQN 和 DDQN 进行 HEMS appliance scheduling, 并与 PSO 进行比较, 说明 model-free DRL 可以在动态环境中通过动作反馈降低电费, 但 reward setting 和 generalization 对性能影响明显 [13]。Mocanu 等人较早将 DRL 用于 building energy management online optimization, 并在包含 PV、EV 和 building appliances 的 Pecan Street 数据上验证了 Deep Q-learning 和 deep policy gradient 方法, 其中 deep policy gradient 更适合在线 energy resource scheduling [16]。Amer 等人系统讨论了 DRL 在 HEMS demand response 中的 state-action pairs、reward function 和 hyperparameters, 指出 DRL 性能高度依赖配置选择, reward 表达和环境变化会显著影响收敛速度、鲁棒性和调度结果 [2]。Shuvo 和 Yilmaz 提出的 HERS 将居民反馈和活动状态纳入 deep RL, 使 HEMS 更加 user-centric, 但该研究也指出其模

型未包含 PV、energy storage、microgrid 和 multi-agent setup, 这为进一步扩展留下空间 [24]。

在多用户和分布式场景下, MADRL 比单智能体 DRL 更适合描述多个家庭或多个 EV 的协同决策。Xu 等人提出 multi-agent reinforcement learning-based data-driven HEM 方法, 将 hour-ahead scheduling 表述为 finite Markov decision process, 并结合 ELM 预测电价和 PV, 再使用 multi-agent Q-learning 对 home appliances 和 EV charging 进行调度 [29]。Lee 等人将 demand-side scheduling 表述为 Markov game, 采用 centralized learning and decentralized execution 的 multi-agent deep actor-critic 方法, 使每个 household agent 在执行阶段仅依赖局部观测, 从而兼顾 scalability 和 privacy preservation [11]。Wang 等人提出基于 multi-stage PPO 和 imitation learning 的 scalable MADRL 方法, 用于 residential hybrid energy system, 并采用 centralized training decentralized execution 来改善 multi-agent system 的 scalability 和 robustness [27]。Park 和 Moon 的 EV charging scheduling 研究同样采用 CTDE 思路, 在 smart grid charging station 中为每个 EV 学习 decentralized charging decision [18]。这些文献表明, MADRL 可以处理多主体之间的耦合与局部观测问题, 是本文选择 multi-agent actor-critic 框架的重要依据。

同时, 安全约束和物理可行性是 DRL/MADRL 在能源系统中落地时必须考虑的问题。Li 等人综述了 DRL 在 smart grid operations 中的应用, 指出 DRL 能够处理 uncertainty、curse of dimensionality 和缺少精确模型的问题, 但仍面临 reward design、learning stability、exploration、sample efficiency 和 simulation-to-reality 等挑战 [12]。Zhang 等人提出 interior-point policy optimization based MADRL, 将 secure HEM 表述为 constrained MDP, 并结合 non-stationary Transformer forecasting, 以在不确定环境下提升 cost efficiency、comfort level 和 safety guarantee [32]。Quakernack 等人将 DDQN-based multi-agent control 用于 low-voltage grid stability, 控制 EV charging 和 BSS charging/discharging, 以改善 voltage drops、transformer overload 和 reverse power flow [19]。这些研究说明, safe DRL 和 grid-aware learning 已成为重要方向。不过在本文中, safety projection 不是唯一核心贡献, 而是服务于 EV charging、BESS operation 和多控制方法比较的辅助机制。

此外, energy management 思想也被用于 vehicle powertrain 等相邻领域。Hao Zhang 等人针对 PHEV powertrain 提出 hierarchical energy management strategy, 在 cloud level 使用 dynamic programming 生成 SOC reference trajectory, 在 powertrain level 使用 DRL 进行 instantaneous optimization [31]。虽然该研究对象不是 residential HEMS, 但其中“全局参考轨迹 + 局部学习控制”的思想说明, SoC reference 和 DRL 可以结合, 用于缓解单纯即时 reward 难以表达长期能量约束的问题。这一点与本文中 EV departure SoC、progress penalty 和 hard feasibility handling 的设计具有概念上的关联。

1.3 面临的挑战与 Research Gap

综上, 现有文献已经从多个角度研究了 HEMS、residential microgrid、BESS scheduling、EV charging、MPC、machine learning、DRL 和 MADRL。然而, 结合本文问题设置后, 仍然存在以下不足。

首先, 许多 HEMS 研究主要关注单个家庭或单个 building 的内部优化, 目标多为降低电费、提高用户舒适度或提升 PV self-consumption [34, 3, 10]。这类研究为家庭能源管理提供了基础, 但对多个 prosumer 同时接入同一低压配电网后的网络耦合考虑不足。对于本文的场景, 三个 prosumer 的 battery charging/discharging、PV curtailment 和 EV charging 会共同改变 feeder net load, 并通过潮流计算影响 bus voltage、line loading 和 transformer loading。因此, 单家庭 HEMS 的结论不能直接替代多 prosumer distribution network energy management。

其次, 传统优化和 MPC 方法能够显式表达设备约束和未来预测信息, 但其性能依赖准确模型、预测质量和求解效率。已有研究表明, MPC 在 residential appliance scheduling、battery peak shaving 和 EV as mobile storage 等问题中具有较强性能 [5, 8, 22]; Mueller 等人的比较也显示, model-based 方法通常能获得更好的 objective value 和 constraint violation 表现 [17]。但是, 当系统同时包含多个 prosumer、BESS、PV、EV、dynamic price 和 network constraints 时, 优化问题规模和求解复杂度会显著增加。尤其在 MISOCP 或 mixed-integer formulation 中, binary variables 和非线性潮流近似会使实时部署更加困难。因此, 需要将 MPC/MISOCP 作为重要 benchmark, 同时探索计算更轻、执行更快的 data-driven controller。

第三, DRL 和 MADRL 适合处理不确定性和在线决策, 但其训练稳定性、reward design 和 constraint satisfaction 仍然是核心挑战。已有 DRL-HEMS 研究显示, DQN、DDQN、deep policy gradient 和 multi-agent Q-learning 可以降低家庭能源成本或改善 demand response 效果 [13, 16, 29]。但 Amer 等人指出, DRL 的表现高度依赖 state-action representation、reward function 和 hyperparameters [2]; Li 等人也强调 reward design、exploration 和 safety 是 smart grid DRL 应用中的重要限制 [12]。对于本文而言, EV charging 具有明显的长时序约束: 如果只在 departure time 给出 penalty, 智能体可能由于 sparse reward 而延迟充电; 如果过度强调 EV cost, 又可能牺牲 battery arbitrage 或导致不合理充电。因此, EV departure requirement 的建模和 reward 设计是本文比一般 HEMS 更关键的问题。

第四, 现有 multi-agent 方法虽然能够处理多个用户或多个 EV 的 decentralized execution, 但同时考虑 residential BESS、PV utilization、EV departure SoC、forecasted price/load/PV 以及配电网运行指标的研究仍然有限。Xu 等人 and Lee 等人展示了 MARL 在 HEM 和 demand-side scheduling 中的潜力 [29, 11], Park 和 Moon 证明 CTDE 方法适合多个 EV 的 charging scheduling [18], Wang 等人则说明 MADRL 可提高 residential hybrid energy system 的 scalability 和 training efficiency [27]。但是这些研究的重点分别偏向 appliance scheduling、charging station、building thermal comfort 或 hybrid energy system, 并不完全对应本文的低压配电网 multi-prosumer 场景。

第五, 电网安全约束在 HEMS 和 DRL 文献中经常被简化处理。Quakernack 等人已经表明, LV grid 中的 EV、BESS 和 PV 会影响 voltage drop、reverse power flow 和 transformer loading, 并且 RL 可以用于 grid stability control [19]。Zhang 等人的 secure HEM 也说明 unrestricted action space 可能违反物理约束, 因此需要 safe MADRL 方法 [32]。但是, 本文的重点不是单独提出一个全新的 safety projection 理论, 而是在多 prosumer EV-BESS-PV 调度中比较不同控制方法, 并分析 soft、hard 和 emergency EV constraint handling 对经济性、EV feasibility 和 grid safety 的影响。因此, 本研究将电网安全作为评价和约束的一部分, 而不是将其作为唯一研究对象。

基于以上 research gap, 本文的研究定位可以概括为: 面向低压配电网中的多个 prosumer, 建立包含 household load、PV generation、stationary BESS、residential EV charging、electricity price 和 power-flow feedback 的能源管理环境; 在同一实验框架下比较 rule-based、Local MPC、ADMM-MPC、MISOCP 和 MADRL 控制器; 重点分析 EV departure SoC requirement 的 soft constraint、hard projection 和 emergency charging 处理方式, 以及这些设计对 total cost、battery arbitrage、EV charging cost、departure SoC 和 distribution network safety 的影响。通过这种方式, 本文试图弥合单家庭 HEMS、优化控制方法和 MADRL 方法之间的差距, 为多 prosumer 场景下 EV 与储能协同控制提供更具体的实验依据。

目前所给文献中, 对低压配电网潮流建模工具、SimBench benchmark、pandapower implementation 以及 ADMM-MPC/MISOCP 在配电网 OPF 中的专门文献覆盖不足。因此, 本章未对这些方向展开详细综述; 若后续希望增强 Chapter 2 的电网建模与优化理论部分, 仍需要补充关于 low-voltage benchmark grid、AC power flow、DistFlow、ADMM optimal power flow 和 MISOCP relaxation 的文献。

Bibliography

- [1] A. O. Ali, M. R. Elmarghany, M. M. Abdelsalam, M. N. Sabry, and A. M. Hamed. “Closed-loop home energy management system with renewable energy sources in a smart grid: A comprehensive review.” In: *Journal of Energy Storage* 50 (2022), p. 104609. ISSN: 2352-152X. DOI: 10.1016/j.est.2022.104609.
- [2] A. Amer, K. Shaban, and A. Massoud. “Demand Response in HEMSs Using DRL and the Impact of Its Various Configurations and Environmental Changes.” In: *Energies* 15.21 (2022). ISSN: 1996-1073. DOI: 10.3390/en15218235.
- [3] M. Beaudin and H. Zareipour. “Home energy management systems: A review of modelling and complexity.” In: *Renewable and Sustainable Energy Reviews* 45 (2015), pp. 318–335. ISSN: 1364-0321. DOI: 10.1016/j.rser.2015.01.046.
- [4] M. Beaudin, H. Zareipour, and A. Schellenberg. “Residential energy management using a moving window algorithm.” In: *2012 3rd IEEE PES Innovative Smart Grid Technologies Europe (ISGT Europe)*. 2012, pp. 1–8. DOI: 10.1109/ISGTEurope.2012.6465896.
- [5] C. Chen, J. Wang, Y. Heo, and S. Kishore. “MPC-based appliance scheduling for residential building energy management controller.” In: *IEEE Transactions on Smart Grid* 4.3 (2013), pp. 1401–1410. DOI: 10.1109/TSG.2013.2265239.
- [6] C. Clastres, T. T. Ha Pham, F. Wurtz, and S. Bacha. “Ancillary services and optimal household energy management with photovoltaic production.” In: *Energy* 35.1 (2010), pp. 55–64. ISSN: 0360-5442. DOI: 10.1016/j.energy.2009.08.025.
- [7] G. T. Costanzo, J. Kheir, and G. Zhu. “Peak-load shaving in smart homes via on-line scheduling.” In: *2011 IEEE International Symposium on Industrial Electronics*. 2011, pp. 1347–1352. DOI: 10.1109/ISIE.2011.5984354.
- [8] D. Dongol, T. Feldmann, M. Schmidt, and E. Bollin. “A model predictive control based peak shaving application of battery for a household with photovoltaic system in a rural distribution grid.” In: *Sustainable Energy, Grids and Networks* 16 (2018), pp. 1–13. ISSN: 2352-4677. DOI: 10.1016/j.segan.2018.05.001.

- [9] N.-e. Id Omar, A. Le-Agopyan, and F. Sossan. “Control and scheduling of behind-the-meter battery energy storage systems for stacked grid and building services.” In: *Smart Energy* 22 (2026), p. 100249. ISSN: 2666-9552. DOI: 10.1016/j.segy.2026.100249.
- [10] X. Jin, K. Baker, D. Christensen, and S. Isley. “Foresee: A user-centric home energy management system for energy efficiency and demand response.” In: *Applied Energy* 205 (2017), pp. 1583–1595. ISSN: 0306-2619. DOI: 10.1016/j.apenergy.2017.08.166.
- [11] J. Lee, W. Wang, and D. Niyato. “Demand-Side Scheduling Based on Multi-Agent Deep Actor-Critic Learning for Smart Grids.” In: *2020 IEEE International Conference on Communications, Control, and Computing Technologies for Smart Grids (SmartGridComm)*. 2020, pp. 1–6. DOI: 10.1109/SmartGridComm47815.2020.9302935.
- [12] Y. Li, C. Yu, M. Shahidehpour, T. Yang, Z. Zeng, and T. Chai. “Deep Reinforcement Learning for Smart Grid Operations: Algorithms, Applications, and Prospects.” In: *Proceedings of the IEEE* 111.9 (2023), pp. 1055–1096. DOI: 10.1109/JPROC.2023.3303358.
- [13] Y. Liu, D. Zhang, and H. B. Gooi. “Optimization strategy based on deep reinforcement learning for home energy management.” In: *CSEE Journal of Power and Energy Systems* 6.3 (2020), pp. 572–582. DOI: 10.17775/CSEEJPES.2019.02890.
- [14] S. N. Makhadmeh, A. T. Khader, M. A. Al-Betar, S. Naim, A. K. Abasi, and Z. A. A. Alyasseri. “Optimization methods for power scheduling problems in smart home: Survey.” In: *Renewable and Sustainable Energy Reviews* 115 (2019), p. 109362. ISSN: 1364-0321. DOI: 10.1016/j.rser.2019.109362.
- [15] A. P. Manjunatha, P. Korba, and V. Stauch. “Integration of large battery storage system into distribution grid with renewable generation.” In: *2013 IEEE Grenoble Conference*. 2013, pp. 1–6. DOI: 10.1109/PTC.2013.6652143.
- [16] E. Mocanu, D. C. Mocanu, P. H. Nguyen, A. Liotta, M. E. Webber, M. Gibescu, and J. G. Slootweg. “On-Line Building Energy Optimization Using Deep Reinforcement Learning.” In: *IEEE Transactions on Smart Grid* 10.4 (2019), pp. 3698–3708. DOI: 10.1109/TSG.2018.2834219.
- [17] F. Mueller, S. de Jongh, C. A. Canizares, T. Leibfried, and K. Bhattacharya. “Comparison of machine learning and MPC methods for control of home battery storage systems in distribution grids.” In: *Applied Energy* 400 (2025), p. 126465. ISSN: 0306-2619. DOI: 10.1016/j.apenergy.2025.126465.

- [18] K. Park and I. Moon. “Multi-agent deep reinforcement learning approach for EV charging scheduling in a smart grid.” In: *Applied Energy* 328 (2022), p. 120111. ISSN: 0306-2619. DOI: 10.1016/j.apenergy.2022.120111.
- [19] L. Quakernack, M. Kelker, and J. Haubrock. “Deep Reinforcement Learning For Autonomous Control Of Low Voltage Grids With Focus On Grid Stability In Future Power Grids.” In: *2022 IEEE PES Innovative Smart Grid Technologies Conference Europe (ISGT-Europe)*. 2022, pp. 1–5. DOI: 10.1109/ISGT-Europe54678.2022.9960416.
- [20] S. Rahim, N. Javaid, A. Ahmad, S. A. Khan, Z. A. Khan, N. Alrajeh, and U. Qasim. “Exploiting heuristic algorithms to efficiently utilize energy management controllers with renewable energy sources.” In: *Energy and Buildings* 129 (2016), pp. 452–470. ISSN: 0378-7788. DOI: 10.1016/j.enbuild.2016.08.008.
- [21] P. R. Satpathy and V. K. Ramachandaramurthy. “Artificial intelligence and machine learning for distributed energy resource management systems: Applications, frameworks, and future directions.” In: *Applied Energy* 403 (2026), p. 127109. ISSN: 0306-2619. DOI: 10.1016/j.apenergy.2025.127109.
- [22] S. Seal, B. Boulet, V. R. Dehkordi, F. Bouffard, and G. Joos. “Centralized MPC for Home Energy Management With EV as Mobile Energy Storage Unit.” In: *IEEE Transactions on Sustainable Energy* 14.3 (2023), pp. 1425–1435. DOI: 10.1109/TSTE.2023.3235703.
- [23] M. Shakeri, M. Shayestegan, H. Abunima, S. M. S. Reza, M. Akhtaruzzaman, A. R. M. Alamoud, K. Sopian, and N. Amin. “An intelligent system architecture in home energy management systems (HEMS) for efficient demand response in smart grid.” In: *Energy and Buildings* 138 (2017), pp. 154–164. ISSN: 0378-7788. DOI: 10.1016/j.enbuild.2016.12.026.
- [24] S. S. Shuvo and Y. Yilmaz. “Home Energy Recommendation System (HERS): A Deep Reinforcement Learning Method Based on Residents’ Feedback and Activity.” In: *IEEE Transactions on Smart Grid* 13.4 (2022), pp. 2812–2821. DOI: 10.1109/TSG.2022.3158814.
- [25] S. Sisodiya, G. B. Kumbhar, and M. N. Alam. “A home energy management incorporating energy storage systems with utility under demand response using PSO.” In: *2018 IEEMA Engineer Infinite Conference (eTechNxT)*. 2018, pp. 1–6. DOI: 10.1109/ETECHNXT.2018.8385345.
- [26] L. Wang, Z. Qin, T. Slangen, P. Bauer, and T. van Wijk. “Grid Impact of Electric Vehicle Fast Charging Stations: Trends, Standards, Issues and Mitigation Measures - An Overview.” In: *IEEE Open Journal of Power Electronics* 2 (2021), pp. 56–74. DOI: 10.1109/OJPEL.2021.3054601.

- [27] Z. Wang, F. Xiao, Y. Ran, Y. Li, and Y. Xu. “Scalable energy management approach of residential hybrid energy system using multi-agent deep reinforcement learning.” In: *Applied Energy* 367 (2024), p. 123414. ISSN: 0306-2619. DOI: 10.1016/j.apenergy.2024.123414.
- [28] J. Wu, S. Li, A. Fu, M. Cvetkovic, P. Palensky, J. C. Vasquez, and J. M. Guerrero. “Hierarchical online energy management for residential microgrids with Hybrid hydrogen–electricity Storage System.” In: *Applied Energy* 363 (2024), p. 123020. ISSN: 0306-2619. DOI: 10.1016/j.apenergy.2024.123020.
- [29] X. Xu, Y. Jia, Y. Xu, Z. Xu, S. Chai, and C. S. Lai. “A Multi-Agent Reinforcement Learning-Based Data-Driven Method for Home Energy Management.” In: *IEEE Transactions on Smart Grid* 11.4 (2020), pp. 3201–3211. DOI: 10.1109/TSG.2020.2971427.
- [30] D. Zhang, S. Li, M. Sun, and Z. O’Neill. “An Optimal and Learning-Based Demand Response and Home Energy Management System.” In: *IEEE Transactions on Smart Grid* 7.4 (2016), pp. 1790–1801. DOI: 10.1109/TSG.2016.2552169.
- [31] H. Zhang, Q. Fan, S. Liu, S. E. Li, J. Huang, and Z. Wang. “Hierarchical energy management strategy for plug-in hybrid electric powertrain integrated with dual-mode combustion engine.” In: *Applied Energy* 304 (2021), p. 117869. ISSN: 0306-2619. DOI: 10.1016/j.apenergy.2021.117869.
- [32] Y. Zhang, R. Lin, Z. Mei, M. Lyu, H. Jiang, Y. Xue, J. Zhang, and D. W. Gao. “Interior-point policy optimization based multi-agent deep reinforcement learning method for secure home energy management under various uncertainties.” In: *Applied Energy* 376 (2024), p. 124155. ISSN: 0306-2619. DOI: 10.1016/j.apenergy.2024.124155.
- [33] M. Zheng, C. J. Meinrenken, and K. S. Lackner. *Electricity storage in buildings for residential sector demand response: Control algorithms and economic viability evaluation*. NIST GCR 14-978. Columbia University, June 2014.
- [34] B. Zhou, W. Li, K. W. Chan, Y. Cao, Y. Kuang, X. Liu, and X. Wang. “Smart home energy management systems: Concept, configurations, and scheduling strategies.” In: *Renewable and Sustainable Energy Reviews* 61 (2016), pp. 30–40. ISSN: 1364-0321. DOI: 10.1016/j.rser.2016.03.047.